


ВАЛЕНТИН АРЬКОВ

Машинное обучение



Валентин Юльевич Арьков

Машинное обучение

Методические указания

Шрифты предоставлены компанией «ПараТайп»

© Валентин Юльевич Арьков, 2026

Темы занятий для самостоятельного изучения

12+

Оглавление

[Машинное обучение](#)

[Предисловие](#)

[Введение](#)

[План занятий](#)

[Введение](#)

[Большие данные](#)

[Загрузка данных](#)

[Распределение](#)

[Библиотеки](#)

[Регрессия](#)

[Классификация](#)

[Кластеризация](#)

[Предварительная обработка](#)

[Конвейер](#)

[ПРОДОЛЖЕНИЕ СЛЕДУЕТ](#)

Предисловие

Студенты обязаны посещать занятия и осваивать образовательную программу. Такие требования оговариваются в Федеральном Законе «Об образовании» и вузовском «Положении об отчислении».

Студент, который пропускает занятия, осваивает материал самостоятельно. Более того, в учебном плане предусмотрено большое количество времени на самостоятельную работу студентов.

Как освоить материал? Книги, онлайн-курсы, конспекты коллег, интеллектуальные чат-боты, поисковые машины – огромное количество возможностей. Было бы желание.

Как не осваивать материал? «А меня не было», «А я не нашла», «А там непонятно», «А мне это не надо», «А я уже работаю» – здесь тоже полный простор для творчества, для поиска оправданий и причин. Большинство из них начинаются с «А»...

Введение

Машинное обучение (МО) – это настройка алгоритмов на основе большого количества примеров желательного и нежелательного поведения компьютерных программ. Это означает, что вычислительная машина (компьютер) обучается на готовых примерах (образцах), то есть подстраивает коэффициенты модели. Затем обученная (настроенная) модель может выдавать прогнозы (предсказания). Обычно у нас надежда, что чем больше обучающих примеров, тем точнее прогнозы.

Компьютерные технологии МО – это алгоритмы и программы. Но основаны эти технологии на давно известных методах статистики и эконометрики. И это более, чем два века исследований с помощью ручки и бумаги.

План занятий

Введение

Искусственный интеллект

Машинное обучение

Глубокое обучение

Многослойные нейронные сети

Экспертные системы

Четыре уровня аналитики: описательная, диагностическая, прогнозная (предиктивная), рекомендательная (предписывающая).

Популярные инструменты МО: Python, Google Colab, Jupyter Notebook, Anaconda.

Библиотеки: NumPy, Pandas, Matplotlib, SK-Learn, Keras.

Платформа Kaggle.

Markdown.

Машинная модель: признаки (features), целевые переменные (target values)

Обучение модели и прогнозирование.

Три типа обучения: контролируемое (supervised learning), неконтролируемое (unsupervised learning), обучение с подкреплением (reinforcement learning)

Классические задачи МО. Регрессия, классификация, кластеризация, уменьшение размерности

Большие данные

Google

Big

Цикл хайпа

Аналитическая компания Гартнер

Наука о данных (Data Science)

DataFrame

Объектно-ориентированное программирование

Класс, экземпляр, атрибуты, методы

Linear regression

fit ()

predict ()

Очистка данных

Пропуски

Недостоверные данные

Инженер по работе с данными (Data Engineer)

API

Аналитик данных (Data Analyst)

Исследователь данных (Data Scientist)

Инженер по МО (ML Engineer)

Большие данные: 3Vs, 5Vs, 7Vs, 9Vs...

ERP (Enterprise Resource Planning)

Корпоративные информационные системы

База данных (Database)

OLAP-куб

Хранилище данных (Data Warehouse)

ETL (Extract, Transform, Load)

Витрина данных (Data Mart)

Кило-мега-гига-экса-...
Табличные данные
Пакетная обработка
Неструктурированные данные
Реальное время

Загрузка данных

Облачный провайдер
Поставщик облачных услуг
Масштабирование (Scaling)
Отдача на масштаб
Параллельное программирование
Масштабируемость (Scalability)
Накладные расходы
Горизонтальное и вертикальное масштабирование (Scale out / scale up)
Математика
Экономика
Статистика
Эконометрика
Разведочный / интеллектуальный анализ данных (Data Mining)
Бизнес аналитика / BI аналитика
Большие Данные
Интернет вещей
Интеллектуальный анализ логов бизнес-процессов (Process Mining)
NoSQL (Not only SQL)
Запись данных по строкам, обработка по столбцам
Колоночные базы данных
Потоковая обработка данных
Табличные данные
API, XML, JSON
CSV (Comma Separated Values) – разделители / локализация
Ограничения Excel
Power Query
Пропуски – Не число / NaN / IEEE 754
read_csv: delimiter, header, names, use columns, data types, missing data
Преобразование и очистка данных
REST API
Open Weather Map

Распределение

Вероятность (probability)
Плотность вероятности
Функция распределения
Распределение значений признака (feature)
Гистограмма
Диаграмма размаха
Правило трех сигм
Диапазон значений (размах вариации)
Функция плотности вероятности (pdf)
Интегральная функция распределения (cdf)
Нормальное распределение (Гаусс)

Норма вектора: сумма квадратов (L2), манхэттенское расстояние (L1)

Нормальные уравнения

Небесная механика

Probability density function, μ , σ

Псевдослучайные числа

NumPy – random

hist ()

density – false

Библиотеки

Популярные библиотеки для анализа данных и МО

Pandas, NumPy, Matplotlib, SciPy, PyTorch, TensorFlow, Keras, Scikit-Learn, XG Boost

Типы: целые, вещественные, логические, строковые

Структуры данных: список Python, массив NumPy, DataFrame Pandas.

Библиотеки, модули, функции, константы, классы

Магические команды Cell Magic %%writefile

Команды Linux в терминале и в кодовой ячейке

Дзен для языка Python: import this

Пасхалка

Двойное подчеркивание dunder (double underscore) __main__

Регрессия

Перцептрон

Метод наименьших квадратов (МНК)

Линейные модели

Ordinary List Squares (OLS)

Linear Regression

Методы fit ()

Атрибуты coefficient, intercept

Документация: API (Application Programming Interface)

Коэффициент детерминации (R-квадрат)

DIR – содержимое объекта

help для экземпляра класса

Dockstring

Многострочный комментарий – справка

Артефакт

Игрушечный датасет

Размерность массива/списка ReShape ()

Линии регрессии $y(x)$ и $x(y)$ – наклон и пересечение

Многослойный перцептрон MLP Regressor

Вес (weight), смещение (bias), функция активации / возбуждения (activation function)

Identity function

Random State

Эквивалентная регрессионная модель

Перцептрон

Скрытый слой

Метод fit () для подгонки параметров

Метод predict () для прогнозирования и построения графика

Результаты обычной линейной регрессии и нейросети с линейной функцией активации

Solver – решатель – метод оптимизации

Логистическая функция

Гиперболический тангенс
ReLU — выпрямитель (диод)
Сигмоидная функция
Linspace — Linear Space
Формулы LaTeX в текстовой ячейке Markdown
Support Vector Machines
Метод опорных векторов для регрессии и для классификации
Эллипсоид рассеяния
Выбросы и аномалии — влияние на регрессию
Робастная (нечувствительная к выбросам) регрессия
RANSAC (Random Sample Consensus)
Inliers / outliers

Классификация

Определение
Примеры применения
Контролируемое обучение (обучение с учителем)
Обучающая выборка
Признаки (Features)
Размеченные данные
Целевая переменная
Косвенный экономический эффект от автоматизации
Функции для генерирования датасета
Классификация SVM (Support Vector Machines)
Ошибки первого и второго рода
False Positive — Ложно положительный диагноз
False Negative — Ложно отрицательный
True Positive
True Negative
Таблица (матрица) ошибок — Confusion matrix
Модуль метрик — metrics
Метрики классификации
Accuracy
Precision
Recall
F1 score
Принятие решений — цена ошибки

Кластеризация

Определение, происхождение
Примеры применения
Центроиды
Меры расстояния / близости
Евклидово
Манхэттенское
Manhattan — Street / Avenue / Broadway
Предобработка
Стандартное нормальное распределение
Генерация данных для кластеризации Make Blobs: количество объектов, центров, признаков
Метод K средних — K Means / KNN
Make moons

DBSCAN

Метрики кластеризации

Силуэт

Внутрикластерная и межкластерная дисперсия

Unsupervised learning

Предварительная обработка

Предобработка Pre-processing

Feature extraction

Normalization

Transform input data

Шкалирование / приведение к масштабу

Пропущенные данные (пропуски)

Нормализация

Стандартизация

Feature Scaling

MinMax Scaler

Labels — метки

Категориальные признаки

Многоклассовая система

LabelEncoder — fit () transform ()

Train Test Split

One-hot encoding — Бегущая единица

Фиктивные переменные — Dummy Variables

Pandas — Get Dummies

OneHotEncoder

DataFrame — GetDummies

D-type: int, float, bool

Inverse Transform ()

Конвейер

Пайплайн — pipeline

CI/CD

Roll out — «выкатить в продакшн»

Pipeline: Standard Scaler — SVCClassifier — fit — метрики качества

fit — transform — predict

fit_predict ()

fit_transform ()

загрузка и объединение 6 файлов ЛР: прочитать файл — выбрать столбцы — очистка данных — шкалирование — фиктивные переменные

Конвейер ETL — массовая загрузка и очистка данных

Объединить датафреймы

Конвейер в командной строке

ПРОДОЛЖЕНИЕ СЛЕДУЕТ