ВАЛЕНТИН АРЬКОВ

Машинное обучение

Валентин Юльевич Арьков

Машинное обучение

Методические указания

Шрифты предоставлены компанией «ПараТайп»

© Валентин Юльевич Арьков, 2026

Темы занятий для самостоятельного изучения

12+

Оглавление

Машинное обучение
Предисловие
Введение
План занятий
- Введение
- Большие данные
- Загрузка данных
- Распределение
- Библиотеки
- Регрессия
- Персептрон
- Продвинутая регрессия
- ПРОДОЛЖЕНИЕ СЛЕДУЕТ

Предисловие

Студенты обязаны посещать занятия и осваивать образовательную программу. Такие требования оговариваются в Федеральном Законе «Об образовании» и вузовском «Положении об отчислении».

Студент, который пропускает занятия, осваивает материал самостоятельно. Более того, в учебном плане предусмотрено большое количество времени на самостоятельную работу студентов.

Как освоить материал? Книги, онлайн-курсы, конспекты коллег, интеллектуальные чат-боты, поисковые машины — огромное количество возможностей. Было бы желание.

Как не осваивать материал? «А меня не было», «А я не нашла», «А там непонятно», «А мне это не надо», «А я уже работаю» — здесь тоже полный простор для творчества, для поиска оправданий и причин. Большинство из них начинаются с «А»...

Введение

Машинное обучение (МО) — это настройка алгоритмов на основе большого количества примеров желательного и нежелательного поведения компьютерных программ. Это означает, что вычислительная машина (компьютер) обучается на готовых примерах (образцах), то есть подстраивает коэффициенты модели. Затем обученная (настроенная) модель может выдавать прогнозы (предсказания). Обычно у нас надежда, что чем больше обучающих примеров, тем точнее прогнозы.

Компьютерные технологии МО — это алгоритмы и программы. Но основаны эти технологии на давно известных методах статистики и эконометрики. И это более, чем два века исследований с помощью ручки и бумаги.

План занятий

Введение

Искусственный интеллект
Машинное обучение
Глубокое обучение
Многослойные нейронные сети
Экспертные системы
Четыре уровня аналитики: описательная, диагностическая, прогнозная (предиктивная), рекомендательная (предписывающая).
Популярные инструменты МО: Python, Google Colab, Jupyter Notebook, Anaconda.
Библиотеки: NumPy, Pandas, Matplotlib, SK-Learn, Keras.
Платформа Kaggle.
Markdown.
Машинная модель: признаки (features), целевые переменные (target values)
Обучение модели и прогнозирование.
Три типа обучения: контролируемое (supervised learning), неконтролируемое (unsupervised learning), обучение с подкреплением (reinforcement learning)
Классические задачи МО. Регрессия, классификация, кластеризация, уменьшение размерности

Большие данные

Google
Big
Цикл хайпа
Аналитическая компания Гартнер
Наука о данных (Data Science)
DataFrame
Объектно-ориентированное программирование
Класс, экземпляр, атрибуты, методы
Linear regression
fit ()
predict ()
Очистка данных
Пропуски
Недостоверные данные
Инженер по работе с данными (Data Engineer)
API
Аналитик данных (Data Analyst)
Исследователь данных (Data Scientist)
Инженер по МО (ML Engineer)
Большие данные: 3Vs, 5Vs, 7Vs, 9Vs...
ERP (Enterprise Resource Planning)
Корпоративные информационные системы
База данных (Database)
OLAP-куб
Хранилище данных (Data Warehouse)
ETL (Extract, Transform, Load)
Витрина данных (Data Mart)

Кило-мега-гига-экза-...
Табличные данные
Пакетная обработка
Неструктурированные данные
Реальное время

Загрузка данных

Облачный провайдер
Поставщик облачных услуг
Масштабирование (Scaling)
Отдача на масштаб
Параллельное программирование
Масштабируемость (Scalability)
Накладные расходы
Горизонтальное и вертикальное масштабирование (Scale out / scale up)
Математика
Экономика
Статистика
Эконометрика
Разведочный / интеллектуальный анализ данных (Data Mining)
Бизнес аналитика / BI аналитика
Большие Данные
Интернет вещей
Интеллектуальный анализ логов бизнес-процессов (Process Mining)
NoSQL (Not only SQL)
Запись данных по строкам, обработка по столбцам
Колоночные базы данных
Потоковая обработка данных
Табличные данные
API, XML, JSON
CSV (Comma Separated Values) — разделители / локализация
Ограничения Excel
Power Query
Пропуски — Не число / NaN / IEEE 754
read_csv: delimiter, header, names, use columns, data types, missing data
Преобразование и очистка данных
REST API
Open Weather Map

Распределение

Вероятность (probability)
Плотность вероятности
Функция распределения
Распределение значений признака (feature)
Гистограмма
Диаграмма размаха
Правило трех сигм
Диапазон значений (размах вариации)
Функция плотности вероятности (pdf)
Интегральная функция распределения (cdf)
Нормальное распределение (Гаусс)

Норма вектора: сумма квадратов (L2), манхэттенское расстояние (L1)
Нормальные уравнения
Небесная механика
Probability density function, mu, sigma
Псевдослучайные числа
NumPy — random
hist ()
density — false

Библиотеки

Популярные библиотеки для анализа данных и МО
Pandas, NumPy, Matplotlib, SciPy, PyTorch, TensorFlow, Keras, Scikit-Learn, XG Boost
Типы: целые, вещественные, логические, строковые
Структуры данных: список Python, массив NumPy, DataFrame Pandas.
Библиотеки, модули, функции, константы, классы
Магические команды Cell Magic %%writefile
Команды Linux в терминале и в кодовой ячейке
Дзен для языка Python: import this
Пасхалка
Двойное подчеркивание dunder (double underscore) __main__

Регрессия

Персептрон
Метод наименьших квадратов (МНК)
Линейные модели
Ordinary List Squares (OLS)
Linear Regression
Методы fit ()
Атрибуты coefficient, intercept
Документация: API (Application Programming Interface)
Коэффициент детерминации (R-квадрат)
DIR — содержимое объекта
help для экземпляра класса
Dockstring
Многострочный комментарий — справка
Артефакт
Игрушечный датасет
Размерность массива/списка ReShape ()
Линии регрессии y (x) и x (y) — наклон и пересечение
Многослойный персептрон MLP Regressor
Вес (weight), смещение (bias), функция активации / возбуждения (activation function)
Identity function
Random State
Эквивалентная регрессионная модель

Персептрон

Скрытый слой
Метод fit () для подгонки параметров
Метод predict () для прогнозирования и построения графика
Результаты обычной линейной регрессии и нейросети с линейной функцией активации

Solver — решатель — метод оптимизации
Логистическая функция
Гиперболический тангенс
RELU — выпрямитель (диод)
Сигмоидная функция
Lispace — Linear Space
Формулы LaTeX в текстовой ячейке Markdown

Продвинутая регрессия

Support Vector Machines
Метод опорных векторов для регрессии и для классификации
Элипсоид рассеяния
Выбросы и аномалии — влияние на регрессию
Робастная (нечувствительная к выбросам) регрессия
RANSAC (Random Sample Consensus)
Inliers / outliers

ПРОДОЛЖЕНИЕ СЛЕДУЕТ