


Валентин Юльевич Арьков

Машинное обучение

Методические указания



Валентин Юльевич Арьков

Машинное обучение

Методические указания

Шрифты предоставлены компанией «ПараТайп»

© Валентин Юльевич Арьков, 2026

Данное пособие предназначено для студентов, изучающих машинное обучение. Здесь мы рассматриваем такие темы, как загрузка данных, регрессия, классификация, кластеризация, понижение размерности и обработка естественного языка. Для первого знакомства с материалом мы делаем акцент на грамотном использовании готовых инструментов — популярных бесплатных библиотек. Подробные планы занятий задают ориентиры по ключевым терминам и технологиям анализа данных.



ОГЛАВЛЕНИЕ

[Машинное обучение](#)

[Вступление](#)

[Предисловие](#)

[Машинное обучение](#)

[Искусственный интеллект](#)

[План занятий](#)

[Введение](#)

[Большие данные](#)

[Загрузка данных](#)

[Распределение](#)

[Библиотеки](#)

[ETL](#)

[Типы и структуры данных](#)

[Диаграмма размаха](#)

[Регрессия](#)

[Дерево решений](#)

[Классификация](#)

[Кластеризация](#)

[Предварительная обработка](#)

[Конвейер](#)

[Снижение размерности](#)

[NLP](#)

[Материалы для изучения](#)

ВСТУПЛЕНИЕ

ПРЕДИСЛОВИЕ

Студенты обязаны посещать занятия и осваивать образовательную программу. Такие требования оговариваются в Федеральном Законе «Об образовании» и вузовском «Положении об отчислении».

Студент, который пропускает занятия, осваивает материал самостоятельно. Более того, в учебном плане предусмотрено большое количество времени на самостоятельную работу студентов.

Как освоить материал? Книги, онлайн-курсы, конспекты коллег, интеллектуальные чат-боты, поисковые машины — огромное количество возможностей. Было бы желание.

Как не осваивать материал? «А меня не было», «А я не нашла», «А там непонятно», «А мне это не надо», «А я уже работаю» — здесь тоже полный простор для творчества, для поиска оправданий и причин. Обратите внимание, что любое оправдание (отмазка) начинается с «А»...

МАШИННОЕ ОБУЧЕНИЕ

Машинное обучение (МО) — это настройка алгоритмов на основе большого количества примеров желательного и нежелательного поведения компьютерных программ. Это означает, что вычислительная машина (компьютер) обучается на готовых примерах (образцах), то есть подстраивает коэффициенты модели. Затем обученная (настроенная) модель может выдавать прогнозы

(предсказания). Обычно у нас надежда, что чем больше обучающих примеров, тем точнее прогнозы.

Компьютерные технологии МО — это алгоритмы и программы. Но основаны эти технологии на давно известных методах статистики и эконометрики. И это более, чем два века исследований с помощью ручки и бумаги.

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ

Интеллектуальные помощники действительно помогают в учебе, если их об этом попросить.

Они могут сгенерировать программу, дать объяснения по любой команде или библиотеке, рассказать про методы и технологии машинного обучения, придумать примеры и исправить ошибку в коде.

Можно просто вставить в окно чат-бота снимок экрана, приложить к запросу файл и получить полезные советы по улучшению кода.

Единственная проблема в том, что искусственный интеллект (ИИ) и онлайн-курсы помогают в учебе только тем, кто хочет учиться. ИИ также помогает тем, кто не хочет учиться, — помогает не учиться и всячески избегать любых умственных усилий.: сгенерировать работу и найти ответы к тестам — все, что раньше называлось «списать», а потом — с появлением интернета — «скачать».

Так что учиться или не учиться — это ваш личный выбор. И это решение сразу отличает специалистов и элиту от основной «серой массы», от «населения».

ПЛАН ЗАНЯТИЙ

ВВЕДЕНИЕ

Искусственный интеллект

Машинное обучение

Глубокое обучение

Многослойные нейронные сети

Экспертные системы

Четыре уровня аналитики: описательная, диагностическая, прогнозная (предиктивная), рекомендательная (предписывающая).

Популярные инструменты МО: Python, Google Colab, Jupyter Notebook, Anaconda.

Библиотеки: NumPy, Pandas, Matplotlib, SK-Learn, Keras.

Платформа Kaggle.

Markdown.

Машинная модель: признаки (features), целевые переменные (target values)

Обучение модели и прогнозирование.

Три типа обучения: контролируемое (supervised learning), неконтролируемое (unsupervised learning), обучение с подкреплением (reinforcement learning)

Классические задачи МО. Регрессия, классификация, кластеризация, уменьшение размерности

БОЛЬШИЕ ДАННЫЕ

Google

Big

Цикл хайпа
Аналитическая компания Гартнер
Наука о данных (Data Science)
DataFrame
Объектно-ориентированное программирование
Класс, экземпляр, атрибуты, методы
Linear regression
fit ()
predict ()
Очистка данных
Пропуски
Недостоверные данные
Инженер по работе с данными (Data Engineer)
API
Аналитик данных (Data Analyst)
Исследователь данных (Data Scientist)
Инженер по МО (ML Engineer)
Большие данные: 3Vs, 5Vs, 7Vs, 9Vs...
ERP (Enterprise Resource Planning)
Корпоративные информационные системы
База данных (Database)
OLAP-куб
Хранилище данных (Data Warehouse)
ETL (Extract, Transform, Load)
Витрина данных (Data Mart)
Кило-мега-гига-экса-...
Табличные данные
Пакетная обработка
Неструктурированные данные
Реальное время

ЗАГРУЗКА ДАННЫХ

- Облачный провайдер
- Поставщик облачных услуг
- Масштабирование (Scaling)
- Отдача на масштаб
- Параллельное программирование
- Масштабируемость (Scalability)
- Накладные расходы
- Горизонтальное и вертикальное масштабирование (Scale out / scale up)
- Математика
- Экономика
- Статистика
- Эконометрика
- Разведочный / интеллектуальный анализ данных (Data Mining)
- Бизнес аналитика / BI аналитика
- Большие Данные
- Интернет вещей
- Интеллектуальный анализ логов бизнес-процессов (Process Mining)
- NoSQL (Not only SQL)
- Запись данных по строкам, обработка по столбцам
- Колоночные базы данных
- Потоковая обработка данных
- Табличные данные
- API, XML, JSON
- CSV (Comma Separated Values) – разделители / локализация
- Ограничения Excel
- Power Query
- Пропуски – Не число / NaN / IEEE 754
- read_csv: delimiter, header, names, use columns, data types, missing data
- Преобразование и очистка данных
- REST API

Open Weather Map

РАСПРЕДЕЛЕНИЕ

Вероятность (probability)

Плотность вероятности

Функция распределения

Распределение значений признака (feature)

Гистограмма

Диаграмма размаха

Правило трех сигм

Диапазон значений (размах вариации)

Функция плотности вероятности (pdf)

Интегральная функция распределения (cdf)

Нормальное распределение (Гаусс)

Норма вектора: сумма квадратов (L2), манхэттенское расстояние (L1)

Нормальные уравнения

Небесная механика

Probability density function, mu, sigma

Псевдослучайные числа

NumPy – random

hist ()

density – false

БИБЛИОТЕКИ

Популярные библиотеки для анализа данных и МО

Pandas, NumPy, Matplotlib, SciPy, PyTorch, TensorFlow, Keras, Scikit-Learn, XG Boost

Типы: целые, вещественные, логические, строковые

Структуры данных: список Python, массив NumPy, DataFrame
Pandas.

Библиотеки, модули, функции, константы, классы

Магические команды Cell Magic %%writefile

Команды Linux в терминале и в кодовой ячейке

Дзен для языка Python: import this

Пасхалка

Двойное подчеркивание dunder (double underscore) __main__

ETL

Extract-Transform-Load

Std 25% 50% 75%

Unique

Int, Float, Object

Загрузка датасета

Pandas

Read csv

Describe

Dtypes

Value counts

Matplotlib.pyplot

Plt. Hist

Plt.scatter

Bins

Xlabel

Ylabel

Title

Plt.show

Box plot

Violin plot

Сигма и ПМКР

Head и tail — голова и хвост поезда

Outliers аномалии выбросы
Ipybnb — скачать и выложить на github
Excel + power query очистка и преобразование данных
Openweathermap api json dict
Markdown
URL
Read csv dataframe
Columns
Names
Pandas excel database данные по столбцам
Интерфейс UI API REST
Default value
Позиционные и именованные аргументы функции
Пропущенные данные — пропуски — NaN

ТИПЫ И СТРУКТУРЫ ДАННЫХ

Задача (дано — найти) — алгоритм и структура данных — программа — решение

Data structures and algorithms DSA course
Структуры и типы данных
Python list, Numpy array, pandas dataframe
Генератор случайных данных
Реализация и Скорость заполнения, изменения, агрегирования
Линейная сложность $T(n) = O(n)$
Mark-up, Mark-down, html, markdown

ДИАГРАММА РАЗМАХА

Box plot vertical horizontal
Quartile
Q1 Q2 Q3

IQR inter quartile range
Правило трех сигм
Pyplot seaborn
To csv
Excel libre office calc
Вставка изображений в текстовую ячейку — файл и буфер обмена
Junior middle senior team lead vibe coding

РЕГРЕССИЯ

Персептрон
Метод наименьших квадратов (МНК)
Линейные модели
Ordinary List Squares (OLS)
Linear Regression
Методы fit ()
Атрибуты coefficient, intercept
Документация: API (Application Programming Interface)
Коэффициент детерминации (R-квадрат)
DIR — содержимое объекта
help для экземпляра класса
Dockstring
Многострочный комментарий — справка
Артефакт
Игрушечный датасет
Размерность массива/списка ReShape ()
Линии регрессии y (x) и x (y) — наклон и пересечение
Многослойный персептрон MLP Regressor
Вес (weight), смещение (bias), функция активации / возбуждения (activation function)
Identity function
Random State

Эквивалентная регрессионная модель
Перцептрон
Скрытый слой
Метод `fit ()` для подгонки параметров
Метод `predict ()` для прогнозирования и построения графика
Результаты обычной линейной регрессии и нейросети
с линейной функцией активации
Solver — решатель — метод оптимизации
Логистическая функция
Гиперболический тангенс
RELU — выпрямитель (диод)
Сигмоидная функция
Lispace — Linear Space
Формулы LaTeX в текстовой ячейке Markdown
Support Vector Machines
Метод опорных векторов для регрессии и для классификации
Эллипсоид рассеяния
Выбросы и аномалии — влияние на регрессию
Робастная (нечувствительная к выбросам) регрессия
RANSAC (Random Sample Consensus)
Inliers / outliers
МНК OLS Linear Regression
Критерий норма вектора
Fit
Predict

ДЕРЕВО РЕШЕНИЙ

Decision Tree
Случайный лес
Random Forest
Диаграмма разброса + прогноз (линия регрессии)
Plot + Scatter

Глубина дерева — количество ступенек
Random State — начальное состояние генератора
Интернет мем «Изолента и смазка WD-40»
Качество прогноза — метрика «R-квадрат»
Перекрестная проверка
Cross Validation
Train Test Split
Обучающая и тестовая (контрольная) выборки + валидация
Графический выбор глубины дерева
Ошибка прогноза с увеличением глубины дерева на обучающей выборке и на тестовой
Модель для прямой линии и для синусоиды с разбросом
Обобщение и переобучение
Лучшее — враг хорошего
Гиперпараметры
Количество деревьев и глубина
Поиск на сетке
Grid Search
Схема дерева
Узлы, условия ветвления, значения
Value — среднее значение на интервале

КЛАССИФИКАЦИЯ

Определение
Примеры применения
Контролируемое обучение (обучение с учителем)
Обучающая выборка
Признаки (Features)
Размеченные данные
Целевая переменная
Косвенный экономический эффект от автоматизации
Функции для генерирования датасета

Классификация SVM (Support Vector Machines)

Ошибки первого и второго рода

False Positive — Ложно положительный диагноз

False Negative — Ложно отрицательный

True Positive

True Negative

Таблица (матрица) ошибок — Confusion matrix

Модуль метрик — metrics

Метрики классификации

Accuracy

Precision

Recall

F1 score

Принятие решений — цена ошибки

прогноз дискретного значения

бинарная классификация

граница между классами

рост, вес, длина волос, пол

male / female — фиктивные переменные / dummy variables

pandas — get dummies

sk learn

KNN — метод K ближайших соседей

скажи мне, кто твой друг, и я скажу тебе, кто ты

схема голосования — нечетное K

граница между классами на диаграмме разброса — подбор K

логистическая регрессия — линейная классификация

граница — прямая линия

решающее дерево

decision tree classifier

глубина дерева — форма границы / количество ступенек

метод опорных векторов

персептрон

функции активации — линейные и нелинейные

КЛАСТЕРИЗАЦИЯ

Определение, происхождение

Примеры применения

Центроиды

Меры расстояния / близости

Евклидово

Манхэттенское

Manhattan — Street / Avenue / Broadway

Предобработка

Стандартное нормальное распределение

Генерация данных для кластеризации Make Blobs: количество объектов, центров, признаков

Метод К средних — K Means / KNN

Make moons

DBSCAN

Метрики кластеризации

Силуэт

Внутрикластерная и межкластерная дисперсия

Unsupervised learning

ПРЕДВАРИТЕЛЬНАЯ ОБРАБОТКА

Предобработка Pre-processing

Feature extraction

Normalization

Transform input data

Шкалирование / приведение к масштабу

Пропущенные данные (пропуски)

Нормализация

Стандартизация

Feature Scaling

MinMax Scaler

Labels — метки
Категориальные признаки
Многоклассовая система
LabelEncoder — fit () transform ()
Train Test Split
One-hot encoding — Бегущая единица
Фиктивные переменные — Dummy Variables
Pandas — Get Dummies
OneHotEncoder
DataFrame — GetDummiesWith
D-type: int, float, bool
Inverse Transform ()
Кодирование признаков
Числовые целые вещественные текстовые логические
бегущая единица
категориальные признаки
упорядоченные категории
Номинальный порядок
Label Encoder
Ordinal Encoder
Missing Value
Float Integer Boolean
Fit_Transform ()
HandleUnknown
UnknownValue
NaN
удалить
impute — Заполнить константами / средними
таблица Google с пропусками — read_csv ()
drop_na ()
simple imputer
Фиксированное значение / среднее / медиана / most frequent
/ мода

центральное значение / тенденция + разброс
fill value
линейная и нелинейная регрессия — степени икс
polynomial_features ()
моделируем синусоиду с разбросом 10%
регрессия по полиномиальным признакам
повышаем степень полинома
train-test-split — metric R^2
коэффициент детерминации / форма графика прогноза
обобщение / переобучение
улавливаем основные особенности и не подстраиваемся под случайности
прогноз погоды — синусоида — средние годовые

КОНВЕЙЕР

Пайплайн — pipeline
CI/CD
Roll out — «выкатить в продакшн»
Pipeline: Standard Scaler — SVCClassifier — fit — метрики качества
fit — transform — predict
fit_predict ()
fit_transform ()
загрузка и объединение 6 файлов ЛР: прочитать файл — выбрать столбцы — очистка данных — шкалирование — фиктивные переменные
Конвейер ETL — массовая загрузка и очистка данных
Объединить датафреймы
Конвейер в командной строке

СНИЖЕНИЕ РАЗМЕРНОСТИ

Dimensionality Reduction

OLAP-кубы — измерения и меры (dimensions, measures)

Dimensionality — количество dimensions

больше признаков — сложность модели

проклятие размерности

число измерений — объем данных — экспонента

многомерные данные — визуализация

датасет Ирисы

количество сортов /классов и признаков / features / измерений

Количество instances / экземпляров

Автор, время, трудоемкость сбор датасета, инструменты

Pair Plot — матрица графиков

библиотека Seaborn SNS

уменьшить количество измерений до двух

построить диаграмму разброса в двух измерениях

PCA

эллипсоид рассеяния

сжатие информации — аналогия с форматом JPEG

датасет MNIST

число изображений, классов, цветов, пикселей

визуализировать в двух измерениях

проверить распознавание на своем собственном примере Paint

вывести изображение в графическом и числовом представлении

вывести свой пример на 2D диаграмме

T-S-N-E или PCA

NLP

Токенизация

Читаем текст из файла в переменную

Разбиение на слова — токены

Token — поиск изображения

Жетон в метро, в телефонных автоматах

чат-бот — оплата за количество токенов в запросе / ответе

токены для английского и русского текста

токен доступа по API — Telegram-бот

API-ключ (токен) для ChatGPT

Библиотеки NLP: NLTK, Spacy, Transformers

метода split ()

разбить на слова по заданным символам

пробелы, знаки препинания, регулярные выражения

исходная форма слова

bag of words

лемматизация и стемминг

Загрузка — токенизация — стемминг для английского и русского текста

разные части речи в разных формах, единственное и множественное число, разные времена, склонения/спряжения/род

Лемматизация для английского и русского текста

частотный анализ текста — гистограмма распределения слов

распределение / закон Ципфа

стоп-слова stop-words

готовые списки «частотных» слов

облако слов Word Cloud

шаблон / маска / форма облака в Paint: черная заливка на белом фоне

семантика

Аналогия — сходство / близость / расстояние / направление

смысловое сходство — векторное представление

«король / королева» «King / Queen»

арифметические действия над векторами

pip install gensim

word2vec — word to vector

Embedding

понижение размерности — 2D визуализация

Метод главных компонент PCA / tSNE

King — вектор

Shape = (300,)

Скаляр

вектор (одномерный массив)

матрица (двумерный массив)

тензор (многомерный массив)

Король — мужчина, королева — женщина

похожие стрелки-векторы

king/queen — man/woman — male/female — boy/girl —
prince/princess

король минус мужчина плюс женщина равно королева

model.mostsimilar () синонимы

столица — страна

времена года / месяцы / осадки

категории слов

стоп-слова

служебные слова

Ключевые слова

сайт библиотеки — библиографическое описание книги

генерируем большой текст про ключевые и служебные слова

Открыть файл, прочитать в переменную

готовая функция по извлечению ключевых слов

лемматизация

извлечь ключевые слова нейросетью

файл прикрепляем к запросу

составление реферата / аннотации — summary / Суммаризация

сделать суммаризацию с помощью библиотеки NLP и нейросети

список стоп-слов

служебные слова

авторский инвариант (процент служебных слов)

Носовский Фоменко Тихий Дон

список служебных слов / произведений / результаты

повторить эксперимент

научная работа — воспроизводимость результатов
закон природы повторяется регулярно в разных условиях

МАТЕРИАЛЫ ДЛЯ ИЗУЧЕНИЯ

Серрано 2024 Грокаем машинное обучение

Теобальд 2024 Машинное обучение для абсолютных новичков

Артемов 2021 Машинное обучение
<https://e.lanbook.com/book/455024>

Араки Масахиро 2020 Машинное обучение. Занимательная
Манга
<https://e.lanbook.com/book/179473>

Митяков 2026 Искусственный интеллект и машинное обучение
<https://e.lanbook.com/book/507451>

Баланов 2026 Машинное обучение и искусственный интеллект
<https://e.lanbook.com/book/513580>

Осин 2026 Машинное обучение с использованием Python
<https://e.lanbook.com/book/501209>

Истратова 2025 Системы искусственного интеллекта и машинное
обучение
<https://e.lanbook.com/book/514567>

Фридман 2024 Little Learner. Чудесное машинное обучение
<https://e.lanbook.com/book/456764>

Хуттер 2023 Автоматизированное машинное обучение AutoML
<https://e.lanbook.com/book/348104>

Котельников 2023 Введение в машинное обучение и анализ данных
<https://e.lanbook.com/book/390698>

Мясников 2023 Распознавание образов и машинное обучение
<https://e.lanbook.com/book/406508>

Чжоу 2025 Машинное обучение сквозь призму Excel
<https://e.lanbook.com/book/514862>

Шарден 2018 Крупномасштабное машинное обучение вместе с Python
<https://e.lanbook.com/book/105836>

Лейн 2023 Машинное обучение для детей
<https://e.lanbook.com/book/358970>

Топольников 2020 Машинное обучение
<https://e.lanbook.com/book/245255>

Флах 2015 Машинное обучение
<https://e.lanbook.com/book/69955>

Рашка 2017 Python и машинное обучение
<https://e.lanbook.com/book/100905>

Арьков В. Ю. Частотный анализ числовых и текстовых данных: Учебное пособие. — [б. м.]: Издательские решения, 2023. — 114 с.
https://ridero.ru/books/chastotnyi_analiz_chislovykh_i_tekstovykh_dannykh/

Арьков В. Ю. Анализ больших данных: Учебное пособие. — [б. м.]:
Издательские решения, 2021. — 220 с.

https://ridero.ru/books/analiz_bolshikh_dannykh/